

RGAT com mais épocas de treino: revisão da hipótese de sub-treino

1 Motivação

`estudo/scibench_ablation.tex` concluiu, a partir de quatro comparações controladas (2 tamanhos de modelo $\times$ 2 benchmarks, todas com 3 épocas de treino), que o RGAT nunca supera sua contraparte T5 pura do mesmo tamanho. Antes de aceitar essa conclusão como definitiva, testamos a hipótese mais óbvia de confusão: será que 3 épocas simplesmente não são treino suficiente para uma arquitetura que adiciona camadas de atenção sobre grafo inicializadas do zero (o RGAT não tem pré-treino próprio, ao contrário do backbone T5)? Se o RGAT precisa de mais gradiente para as camadas novas convergirem, o resultado anterior mediria sub-treino, não uma limitação real da arquitetura.

Para testar isso, re-treinamos as duas configurações com RGAT no ScienceBenchmark por **10 épocas** (mesmos dados, mesmos hiperparâmetros de *learning rate*/otimizador/*batch* efetivo das rodadas de 3 épocas – único fator alterado é `num_train_epochs`):

- **t5-small + RGAT**: `graphix-scibench-t5small-rgat-10ep`
- **t5-base + RGAT completo** (+oncomx, *gradient checkpointing*): `graphix-scibench-finetune-gc-10ep`

2 Resultado principal

Table 1: Comparação 3 épocas vs. 10 épocas (melhor checkpoint por `eval_loss`), dev set do ScienceBenchmark.

Configuração	<code>eval_loss</code>	<code>exact match</code>	<code>exec</code>	tempo de treino
t5-small + RGAT, 3 épocas	1,1517	1,04%	0,68%	3h46min
t5-small + RGAT, 10 épocas	0,9243	5,19%	4,10%	6h59min
t5-base + RGAT completo, 3 épocas	1,6765	0,0%	0,34%	9h42min
t5-base + RGAT completo, 10 épocas	1,4567	0,0%	2,73%	16h13min

O achado é inequívoco: mais épocas melhoram substancialmente o RGAT em ambos os tamanhos de modelo. A Figura 1 mostra que a melhora não satura nas 3 épocas originais – pelo contrário, o *eval_loss* de ambos os modelos continua caindo de forma quase monotônica até a época 9–10, e a *execution accuracy* sobe junto (com ruído normal de treino, mas sem sinal de platô).

- **t5-small + RGAT**: `eval_loss` caiu 20% ($1,15 \rightarrow 0,92$), `exec` subiu $6\times$ ($0,68\% \rightarrow 4,10\%$) e `exact match` subiu $5\times$ ($1,04\% \rightarrow 5,19\%$).
- **t5-base + RGAT completo**: `eval_loss` caiu 13% ($1,68 \rightarrow 1,46$), `exec` subiu $8\times$ ($0,34\% \rightarrow 2,73\%$). `Exact match` permanece em 0% nas duas durações de treino.

RGAT: efeito de mais épocas de treino (3 vs. 10)




Figure 1: Eval loss e métricas discretas por época, 3 vs. 10 épocas, para os dois modelos com RGAT.

3 O que isso muda na conclusão anterior

A conclusão de `estudo/scibench_ablation.tex` – “o RGAT nunca vence sua contraparte do mesmo tamanho” – **precisa ser matizada, não descartada**. Dois pontos ficam mais claros agora:

1. Sub-treino era parte real da explicação. Com apenas 3 épocas, o RGAT estava genuinamente longe de convergir: suas camadas de atenção sobre grafo, inicializadas do zero, exigem mais passos de gradiente que o backbone T5 pré-treinado para chegar perto de um bom ponto de operação. Isso não era visível na comparação de 3 épocas porque não havia uma segunda duração de treino para contrastar – descartar essa hipótese sem testá-la teria sido prematuro.

2. Mesmo com 10 épocas, o RGAT continua atrás do T5 puro. Comparando com o t5-base sem RGAT (Tabela 1 de `estudo/scibench_ablation.tex`: exec 8,19%, treinado em apenas 3 épocas), o t5-base + RGAT completo com 10 épocas (exec 2,73%) ainda fica bem atrás – e treinou mais que o *dobro* do tempo (16h13 vs. 4h13) para chegar lá. Ou seja: mais treino claramente ajuda o RGAT, mas não fecha a lacuna para o T5 puro dentro do orçamento testado. Não podemos afirmar que o RGAT alcançaria ou superaria o T5 puro com treino ainda mais longo – apenas que a comparação de 3 épocas subestimava o potencial do RGAT, e que a arquitetura continua exigindo mais recursos computacionais por unidade de ganho do que o T5 puro nesta tarefa e neste regime de dados.

Conclusão revisada: “RGAT precisa de mais treino” é **confirmado** como fator real – não é apenas uma hipótese descartável. Mas “RGAT supera T5 puro” continua **não confirmado** mesmo com o triplo de épocas; o gargalo observado originalmente é uma combinação de sub-treino (agora corrigido em parte) e um custo-benefício computacional que ainda favorece o T5 puro neste conjunto de experimentos.

Comparação final: 3 vs. 10 épocas (RGAT)




Figure 2: Comparação final (melhor checkpoint) entre as quatro rodadas.