

Ablação RGAT vs. T5 puro no ScienceBenchmark

1 Introdução

Esta nota completa a matriz 2×2 de ablação (tamanho do modelo × presença de RGAT) no ScienceBenchmark, complementando `docs/sciencebenchmark-eval-results.tex` (t5-small sem RGAT, t5-base com RGAT completo) e `estudo/spider_ablation.tex` (o mesmo experimento no Spider). Aqui documentamos as duas células que faltavam: **t5-base sem RGAT** e **t5-small com RGAT** (treinado do zero, sem pré-treino no Spider), ambos com os mesmos dados e hiperparâmetros (3 épocas, lote efetivo 32, 5×10^{-5} com adafactor) dos demais fine-tunings no ScienceBenchmark.

2 Tabela de métricas

Table 1: Todas as configurações do ScienceBenchmark, dev set (289/287 exemplos pontuados).

Configuração	exact match	exec	eval_loss	train_loss	tempo de treino
t5-small sem RGAT	1,38%	1,37%	1,1825	1,0452	2h53min
t5-small com RGAT	1,04%	0,68%	1,1517	0,9977	3h46min
t5-base sem RGAT	7,27%	8,19%	0,8010	0,5051	4h13min
t5-base com RGAT (completo, +oncomx, gc)	0,0%	0,34%	1,6765	2,2152	9h42min

3 Achados

1. Tamanho do modelo domina. t5-base sem RGAT (7,27%/8,19%) é, de longe, a melhor configuração do ScienceBenchmark inteiro – superando inclusive o zero-shot com RGAT (9,0%/8,87%¹ em *exec*, embora ainda um pouco atrás em *exact match*) e todas as demais tentativas de fine-tuning. Nenhuma configuração *com* RGAT chega perto: mesmo o melhor caso com RGAT (t5-small, 0,68% *exec*) fica mais de 10× atrás do t5-base sem RGAT.

2. RGAT nunca vence sua contraparte do mesmo tamanho. Com t5-small controlado (mesmo modelo, mesmos dados, mesmos hiperparâmetros), **sem** RGAT vence **com** RGAT em ambas as métricas (1,38%/1,37% vs. 1,04%/0,68%) e ainda treina mais rápido (2h53 vs. 3h46 – RGAT tem o custo computacional extra de construir e propagar mensagens pelos grafos de até 1300 nós do *oncomx*). Esta é a comparação mais controlada de todo o trabalho (mesmo tamanho de modelo, única variável = presença de RGAT) e o resultado é inequívoco.

3. O padrão se repete em ambos os benchmarks. A Figura 1 mostra as quatro curvas de *exec* ao longo do treino: t5-base sem RGAT destacado muito acima de todas as outras, que ficam próximas de zero e embaralhadas entre si. Combinado com `estudo/spider_ablation.tex` (onde t5-base sem RGAT também praticamente empata com o checkpoint RGAT de referência no Spider), a evidência agora cobre **quatro** comparações independentes (2 tamanhos de modelo × 2 benchmarks) e todas apontam na mesma direção: dentro do orçamento de treino usado neste trabalho, a estrutura de grafo do RGAT não demonstrou vantagem sobre um T5 padrão do mesmo tamanho – em nenhuma delas.

¹Ver `docs/sciencebenchmark-eval-results.tex`, Tabela 1.




Figure 1: Execution accuracy de validação, todas as quatro configurações do ScienceBenchmark.

4 Curvas de treino




Figure 2: t5-base sem RGAT no ScienceBenchmark – curvas de treino completas.

t5-small com RGAT -- ScienceBenchmark




Figure 3: t5-small com RGAT no ScienceBenchmark – curvas de treino completas.