

Ablação RGAT vs. T5 puro no Spider

1 Introdução

Esta nota documenta um experimento de ablação complementar ao estudo principal no ScienceBenchmark: treinar variantes *sem* RGAT (t5-small e t5-base padrão, sem nenhuma estrutura de grafo) diretamente no Spider – o mesmo benchmark e orçamento de treino (5 épocas) usados para produzir o checkpoint de referência com RGAT (t5-base + RGAT, 41,9% *exact match* / 44,8% *execution accuracy* no dev set do Spider, 1034 exemplos). O objetivo é isolar se a vantagem do RGAT observada na literatura se sustenta quando comparada a um T5 padrão treinado com o mesmo orçamento, no próprio terreno de origem da arquitetura (esquemas pequenos e homogêneos do Spider).

2 Tabela de métricas

Table 1: Todas as métricas de avaliação, dev set completo do Spider (1034 exemplos).

Configuração	exact match	exec	eval_loss	train_loss	tempo de treino
t5-base + RGAT (referência)	41,9%	44,8%	–	–	–
t5-small sem RGAT (5 épocas)	13,93%	16,25%	0,5965	1,2751	1h42min
t5-base sem RGAT (5 épocas)	41,10%	43,81%	0,2526	0,5793	3h12min

A linha de referência (t5-base + RGAT) reflete o checkpoint já publicado no estudo principal (docs/sciencebenchmark-eval-results.tex), treinado com a mesma metodologia (5 épocas, mesmo split de treino/dev) – eval_loss/train_loss/tempo de treino não foram re-extraídos para esta nota. As demais linhas são de treinos novos, executados especificamente para esta ablação.

3 Achado principal

O resultado é notável: o **t5-base sem RGAT praticamente empata com o checkpoint RGAT de referência** (41,10% vs. 41,9% exact match; 43,81% vs. 44,8% exec – uma diferença de menos de 1 ponto percentual em ambas as métricas). Isso contrasta com a intuição de que o RGAT, desenhado especificamente para o Spider, deveria trazer uma vantagem clara neste benchmark. O t5-small sem RGAT, por outro lado, fica bem atrás (13,93%/16,25%) – aqui a diferença é dominada pelo tamanho do modelo (60M vs. 220M parâmetros), não pela ausência de RGAT.

Combinado com o achado já registrado no estudo do ScienceBenchmark (onde um t5-small sem RGAT chegou a *superar* o t5-base com RGAT), a evidência consistente entre os dois benchmarks é: dentro do orçamento de treino usado neste trabalho, a estrutura de grafo do RGAT contribui muito menos do que o tamanho do modelo base para o desempenho final – inclusive no Spider, onde a arquitetura foi originalmente desenhada e validada.

4 Curvas de treino




Figure 1: Execution accuracy de validação ao longo do treino, t5-small vs. t5-base sem RGAT no Spider, com a referência RGAT marcada.




Figure 2: t5-small sem RGAT no Spider – curvas de treino completas.

t5-base sem RGAT -- Spider




Figure 3: t5-base sem RGAT no Spider – curvas de treino completas.